

3 基于可微光线追踪的定日镜面型优化方法

在塔式太阳能热发电系统中，定日镜面型是影响聚光性能的关键因素。传统的面型优化方法严重依赖大量重复的光线追踪仿真，存在计算成本高、优化效率低的瓶颈。为解决此问题，本章提出一种基于可微光线追踪的定日镜面型优化方法。该方法的核心在于构建光线传播过程与面型参数之间的可微映射，从而可利用梯度信息高效求解优化问题。本章引入光斑能量集中度 S_{95} 作为优化目标，并系统性地阐述该方法的两个组成部分：前向聚光仿真和后向面型优化。为验证所提出方法的准确性和有效性，通过实际镜场光斑数据对前向聚光仿真算法进行了精度验证，并通过与启发式算法对比在单镜焦距优化中的结果，系统评估方法在收敛速度和计算效率方面的优势。

3.1 定日镜面型优化流程

基于可微光线追踪的定日镜面型优化方法主要分为两个组成部分：前向定日镜聚光仿真和后向定日镜面型优化。在前向定日镜聚光仿真环节中，对塔式太阳能系统中定日镜反射太阳辐射至集热器表面形成反射光斑的过程进行仿真计算，并根据得到的光斑能量分布情况计算目标函数；在后向定日镜面型优化环节中，计算目标函数关于定日镜面型参数的梯度，并据此更新优化定日镜面型参数。优化过程如图 3.1 所示。




图 3.1 定日镜面型优化流程图

具体步骤如下：

(1) 设置仿真场景参数，包括集热器类型、太阳辐射条件、定日镜规格等场景参数，为后续仿真提供基础配置。

(2) 初始化定日镜面型参数。根据优化的定日镜种类选择合适的面型参数并设置初值。

(3) 前向定日镜聚光仿真。基于当前的面型参数，首先计算定日镜表面法向情况，根据面型参数确定镜面各采样点的空间坐标和法向量；然后采用全通路反向蒙特卡洛光线追踪算法模拟光线从集热器表面出发经定日镜反射至太阳圆盘的过程，得到集热器表面的辐射能密度分布图；最后根据辐射能密度分布图计算目标函数 S_{95} ，具体计算过程将在 3.2.2 中提出。

(4) 后向定日镜面型优化。在完成前向仿真后，利用自动微分技术计算目标函数关于定日镜面型参数的梯度，进而采用梯度下降算法确定参数更新方向和步长，最后再更新相应定日镜面型参数。

(5) 重复步骤 (3) 至 (4)，直到达到收敛，收敛条件为目标函数的变化小于设定阈值或达到迭代次数上限。

(6) 终止，得到最优定日镜面型参数。

3.2 前向定日镜聚光仿真

3.2.1 定日镜聚光仿真原理

前向仿真计算的目标是计算集热器上的辐射能分布。在仿真计算过程中，需要计算每根光线的能量，以精确模拟光斑的辐射能密度分布。为此，本文采用一种并行计算的全通路反向蒙特卡洛光线追踪算法^[37]。这里的全通路是指考虑光线在定日镜的玻璃层和反射层的折射和反射。实际物理世界中，光线从太阳出发经过定日镜的折射和反射后到达集热器表面。在反向光线追踪算法中，与实际物理过程不同，基于光路可逆原理，令光线从集热器出发，经过定日镜到达太阳，如图 3.2 所示。




图 3.2 全通路反向蒙特卡洛光线追踪方法示意图

全通路蒙特卡洛反向光线追踪算法首先将集热器表面均匀离散成 $N_p = N_h \times N_v$ 个像素，其中 N_h 和 N_v 分别为水平方向和垂直方向的像素个数。集热器上每个像素 (h, v) 的辐射能密度值 $E(h, v)$ 通过式(3-1)计算：

$$E(h, v) = \sum_{n=0}^{N_s} \frac{E(x_n, y_n)}{N_s} \quad (3-1)$$

其中， N_s 为集热器像素 (h, v) 内的采样点个数，在像素内均匀采样。 $E(x_n, y_n)$ 为每个采样点的辐射能密度值。

设 p 为像素 (h, v) 内的一个采样点，则采样点 p 的辐射能密度 $E(p)$ 可有半球空间 Ω 内所有方向辐射强度的积分得到，如式(3-2)所示。

$$E(p) = \int_{\Omega} L(p, \omega_i) \cos \theta_i d\omega_i \quad (3-2)$$

其中， ω_i 为光线从集热器到定日镜的方向矢量， θ_i 为集热器上采样点 p 的法向量 $\vec{n}_R$ 与光线方向 ω_i 的夹角， $L(p, \omega_i)$ 表示的是集热器上的采样点 p 接收的来自 ω_i 方向的辐射能。

在计算半球空间积分时，许多来自天空或地面方向的光线对能量计算没有贡献。为了避免光线采样的浪费和加快仿真速度，本文采用重要性采样技术，将半球积分转换为对定日镜面积的积分，仅考虑来自定日镜方向的光线贡献。下面对重要性采样和光线能量计算进行详细的描述。

(1) 重要性采样

半球空间由贡献能量的区域和不贡献能量的区域组成，贡献能量的区域由定日镜的面积决定，即图 3.2 中 $d\omega_i$ 表示的区域。根据立体角和余弦效应的定义，由式(3-3)计

算 $d\omega_i$ ，其中 r 为定日镜上的微元 dA 与采样点 p 之间的距离， θ_h 为定日镜法向 $\vec{n}_h$ 与 ω_i 之间的夹角，代入式(3-2)可得到式(3-4)。

$$d\omega_i = \frac{\cos\theta_h}{r^2} dA \quad (3-3)$$

$$E(p) = \int_A L(p, \omega_i) \cos\theta_i \frac{\cos\theta_h}{r^2} dA \quad (3-4)$$

利用蒙特卡洛积分法计算式(3-4)得到采样点 p 的辐射能密度，可以得到式(3-5)：

$$E(p) \approx \frac{A}{N_r} \sum_{i=1}^{N_r} L(p, \omega_i) \cos\theta_i \frac{\cos\theta_h}{r^2} \quad (3-5)$$

其中， N_r 为单个定日镜上均匀采样点个数， A 为单个定日镜面积。

每个集热器像素内部有 N_s 个采样点，因此计算每个像素的辐射能密度需要追踪和计算 $N_s \times N_r$ 根光线，计算集热器所有像素的辐射能密度分布需要追踪和计算 $N_p \times N_s \times N_r$ 根光线。由于每根光线的计算都是相互独立的，可以采用光线级并行对这些光线进行能量计算来加速前向聚光仿真过程。

(2) 光线能量计算

采样点 p 来自 ω_i 方向的光线辐射能 $L(p, \omega_i)$ 受大气衰减效应和太阳辐射强度影响，采用式(3-6)计算：

$$L(p, \omega_i) = L_{sun}(\theta_{sun}) \times \eta_{atm} \quad (3-6)$$

其中， η_{atm} 大气衰减系数，由式(2-5)计算得到； $L_{sun}(\theta_{sun})$ 为太阳辐射强度采用 2.1.1 中的太阳形状 Buie 模型进行计算。

由于太阳辐射强度 $L_{sun}(\theta_{sun})$ 是径向角位移 θ_{sun} 的函数，因此在计算光线的太阳辐射强度之前需要计算定日镜的法向和光线在定日镜中的全通路情况，从而计算出射光线方向 ω_r 与径向角位移 θ_{sun} 。假设定日镜在集热器上的瞄准点为 O_h ，太阳光主方向为 S ，定日镜中心为 C_h ，可由式(3-7)计算定日镜宏观法向 $\vec{n}_h$ 。

$$n_h = \frac{O_h - C_h + S}{\|O_h - C_h + S\|} \quad (3-7)$$

考虑到定日镜表面并不是完全的光滑平面，采用 Gaussian 分布表示定日镜表面每个点的法向扰动。在仿真过程中，对每根入射光线通过定日镜微观法向量计算反射光线的方向 ω_r ，并根据式(3-8)计算出每根光线的径向角位移 θ_{sun} 。

$$\theta_{sun} = \arccos(\omega_r \cdot S) \quad (3-8)$$

随后, 通过太阳形状模型 **Buie** 来计算光线的太阳辐射强度, 该模型描述了太阳相对辐射强度 $\hat{L}_{Buie}(\theta_{sun})$ 与径向角位移 θ_{sun} 之间的关系, 还需要经过式(3-9)转换才能用于计算光线辐射能, 光线辐射能计算如式(3-10)所示。

$$\check{L}_{Buie}(\theta_{sun}) = \frac{\hat{L}_{Buie}(\theta_{sun})}{\int_0^{Solardish+auerole} \hat{L}_{Buie}(\theta_{sun}) \theta_{sun} 2\pi d\theta_{sun}} \quad (3-9)$$

$$L_{sun}(\theta_{sun}) = DNI \times \check{L}_{Buie}(\theta_{sun}) \quad (3-10)$$

其中, DNI 指的是垂直于太阳的单位面积接受到的太阳辐射能, 即直接法向辐照度 (Direct Normal Irradiance, DNI); $\hat{L}_{Buie}(\theta_{sun})$ 为 **Buie** 模型定义的相对辐射强度分布函数; $\check{L}_{Buie}(\theta_{sun})$ 是经过立体角积分归一化后、用于能量计算的太阳辐射强度分布函数; 积分上限 *Solardish + auerole* 表示太阳光盘和光晕的角半径之和, 即太阳有效辐射区域的边缘角。

将式(3-10)代入式(3-6)可得采样点 p 接收到的来自 ω_i 方向的光线辐射度 $L(p, \omega_i)$ 计算如式(3-11)所示。

$$L(p, \omega_i) = DNI \times \check{L}_{Buie}(\theta_{sun}) \times \eta_{atm} \quad (3-11)$$

整个仿真计算中会对 $N_p \times N_s \times N_r$ 根光线进行 GPU 并行采样和计算, 得到集热器上每个采样点的辐射能密度 $E(p)$, 从而实现集热器表面辐射能密度分布的快速仿真, 获得精确的反射光斑能量分布情况。

3.2.2 目标函数的计算与可微化

通过前向聚光仿真得到集热器表面辐射能密度分布后, 需要建立定日镜聚光性能的评价函数。此前研究在对比不同定日镜面型的性能表现时, 经常采用溢出损失、集热器截断效率等与能量有关的性能指标, 但这些性能指标与集热器的种类、尺寸有关。对于给定尺寸和位置的单个定日镜, 更需要关注反射光斑是否汇聚。光斑面积越小, 光能溢出越少, 辐射能密度越高, 集热器表面温度以及发电效率也越高。假设反射光斑的某一等值轮廓所包围的区域包含了光斑总能量的 95%^[37], 则该区域的面积称为 S_{95} , 如图 3.3 所示, 红线内的区域总能量占据光斑总能量的 95%。 S_{95} 越小, 表示辐射能量越集中, 定日镜的聚光能力越强。此外, 在集热器尺寸足够大的情况下, 可以仅采用 S_{95} 这一直观的性能指标来描述一个镜场内所有定日镜的聚光能力。因此, 本文采用 S_{95} 来描

述定日镜反射光斑的质量。




图 3.3 目标函数 S_{95} 示意图

根据定义， S_{95} 是光斑图中位于 95%能量轮廓线以内的像素面积之和，可以通过式(3-12)进行判断累计布尔值得到：

$$S_{95} = S_{pixel} \times \sum_{pixel} I(E(h, v)) \quad (3-12)$$

$$I(E(h, v)) = \begin{cases} 1, & E(h, v) \geq level_{95} \\ 0, & E(h, v) < level_{95} \end{cases}$$

其中， $E(h, v)$ 为集热器上像素 (h, v) 的辐射能密度值，可以通过蒙特卡洛光线跟踪仿真得到，如在 3.2.1 中所述。 $I(E(h, v))$ 为指示函数，用于判断当前像素 (h, v) 是否属于 S_{95} ， $level_{95}$ 为当前光斑图中 S_{95} 的轮廓界限值。 S_{pixel} 为一个像素的面积。

显然，由式(3-12)计算得到的 S_{95} 是像素辐射能密度值 $E(h, v)$ 的布尔判断结果的求和运算，关于定日镜面型参数不可微，如果直接将 S_{95} 作为目标函数用于定日镜面型优化问题，无法利用基于梯度信息的优化算法。因此，对于不可微的目标函数 S_{95} ，在优化过程中需要额外的技术处理其不可微性。

在前向聚光仿真过程中，像素辐射能密度值 $E(h, v)$ 关于面型参数是可微的，但在 S_{95} 计算过程中由于将辐射能密度值映射成离散的面积值，无法建立辐射能密度值与 S_{95} 之间的光滑映射关系，导致梯度信息无法通过链式法则传递到面型参数。为了在评估每个像素是否属于 S_{95} 的同时不损失该像素辐射能密度值的梯度信息，本文借鉴神经网络中的激活函数，激活函数决定了神经元是否被激活，同时保留神经元的梯度信息^[57]。 $sigmoid$ 函数是一种常见的激活函数^[58]，如式(3-13)所示：

$$\text{sigmoid}(x) = \frac{1}{1 + e^{-\alpha(x-c)}} \quad (3-13)$$

其中， α 控制函数的缩放， c 为函数偏移量。

由于 sigmoid 函数的非线性特性，当值接近 0 或 1 时，其曲线变化缓慢，而在中间范围内平滑且陡峭，如图 3.4 所示。这一非线性特性使得 sigmoid 函数能够准确地将集热器上的像素值映射到 $[0,1]$ 范围内。此外， sigmoid 函数具有平滑、易于求梯度的特性，能够在映射的过程中顺利获得变量的梯度。本文将 sigmoid 函数应用于从前向仿真得到的辐射能密度分布图，将像素值映射到范围 $[0,1]$ 。




图 3.4 sigmoid 函数曲线图

通过将每个像素的辐射能密度值代入设计好的 sigmoid 函数，原本属于 S_{95} 区域的像素值将会趋近 1，而 S_{95} 区域外的像素值将会趋近 0。然后通过对所有转换后的像素值求和来计算变换后的 S_{95} ，结果与原始光斑的 S_{95} 数值相同。这种方法保留了每个像素的辐射能密度中的梯度信息，使得梯度信息能够从 S_{95} 传播到定日镜面型参数。虽然有些像素可能位于过渡区，但这些像素的数量有限，对 S_{95} 的计算结果影响微乎其微。

通过 sigmoid 函数对光斑辐射能密度分布图进行平滑处理，构造一个可微的新 S_{95} 函数作为目标函数，如式(3-14)所示。对于本文的反射光斑，通过对比不同的平滑因子 α 值，发现当平滑因子 $\alpha = 1$ 时，处理前后 S_{95} 值几乎相同，因此本文后续实验均采用 $\alpha = 1$ 的配置。反射光斑在 sigmoid 函数处理前后示意图如图 3.5 所示，图 3.5(a)为原始的光斑辐射能密度图，红圈为 S_{95} 等值线；图 3.5(b)为处理后的图像，红色和蓝色的分界线对应 S_{95} 等值线。能够发现经过变换处理前后所得 S_{95} 范围几乎一致，且两种方式计算得到的 S_{95} 数值几乎一致。该变换的核心价值在于使 S_{95} 函数满足可微性要求， sigmoid 函数在 S_{95} 和面型参数之间建立了链式关系，从而可以通过链式法则获得相对于定日镜面型

参数的梯度。

$$S_{95} = \sum_{\text{pixel}} \frac{1}{1 + e^{-(\text{Flux}(h,v) - \text{level}_{95})}} \quad (3-14)$$




图 3.5 sigmoid函数处理前后光斑对比图

3.3 后向定日镜面型优化

在完成对塔式太阳能电站场景的光斑仿真并计算目标函数之后，目标函数对于定日镜面型参数的梯度信息需要借助自动微分工具计算，在获取梯度信息后采用梯度下降算法对面型参数进行更新。

3.3.1 利用自动微分计算梯度

在基于梯度的优化算法中，获取梯度的方法主要包括手动微分、数值微分、符号微分和自动微分（Automatic Differentiation, AD）^[59]。在定日镜面型优化中，目标函数由光线追踪计算得到，公式复杂且需要计算大量梯度，手动微分显然是不现实的。数值微分是通过有限差分对函数实际梯度的近似计算，但由于存在截断和舍入误差，无法满足问题的精度要求^[60]。符号微分虽然能够避免手动微分和数值微分的一些问题，但是在面对程序中的循环结构、条件结构时会出现“表达式膨胀”的问题。相比之下，自动微分能够将复杂函数拆分成初等数学计算公式，并运用链式法则求梯度；同时自动微分不仅可以应用于显式数学表达式，还能够处理程序中的递归、循环等结构，因此自动微分能够计算任意代码的精确梯度，并且在精度、效率和适用性方面都要优于其他方法。

近年来，机器学习技术的兴起驱动着自动微分技术研究进一步发展，自动微分技

术逐渐从数值工具变成编程语言、计算框架的一部分，从而衍生扩展出了更通用的可微编程（Differentiable Programming）^[57]。目前，已经有许多支持反向累计自动微分的计算框架，如 Pytorch^[61]、Tensorflow^[62]、Taichi^[63]等。其中 Taichi 是一种嵌入在 python 中的图形渲染编程语言，不仅支持自动并行化和 GPU 加速，还内置了反向模式自动微分（reverse-mode AD）^[64]，能够将用户定义的前向仿真过程自动构建为计算图，并在后向传播中高效计算梯度。本章的可微光线追踪优化框架是在 Taichi 编程语言中实现的，其中的自动微分技术能够计算在 3.2.1 中的全通路光线追踪算法的梯度信息。




图 3.6 可微蒙特卡洛光线追踪计算图

在 Taichi 中，整个光线追踪过程可被抽象为一个描述梯度传播过程的计算图，如图 3.6 所示。在可微蒙特卡洛光线追踪算法中，首先需要将场景参数等相关变量定义为 Taichi 中的可微变量，尤其是定日镜面型参数。随后遵从 Taichi 语言逻辑实现可微光追算法并确保每一步的计算都是可微。在 Taichi 中，条件分支会被自动处理成可微的选择算子^[65]，并通过固定的伪随机种子使得随机抽样过程可微，计算过程中的每个公式或者变量都会表示为一个节点，相邻节点之间进行数据的传递。基于可微蒙特卡洛光线追踪的定日镜面型优化方法主要分成两个阶段：在前向仿真计算的过程中（即图中红色箭头部分），计算按照顺序执行，相邻节点之间的梯度信息会被储存；在后向梯度传播的过程中（即图中蓝色箭头部分），梯度会根据链式法则进行传播和计算。梯度计算会从目标函数相对集热器像素的辐射能量密度的梯度开始，沿着光线路径传播到定

日镜的每个表面采样点的法向，最终梯度会累计到定日镜面型参数。

此外，由于光线追踪过程具有高度并行性，每条光线在传播、相交判断及反射、折射计算中均相互独立，适于在 GPU 上实现大规模并行加速。在 Taichi 框架中，GPU 不仅加速了前向仿真过程，还在后向传播过程中帮助并行计算每根光线的梯度，进一步提高了计算效率和优化速度。

3.3.2 梯度下降算法

可微光线追踪优化框架采用梯度下降算法高效求解定日镜面型参数。本文采用自适应矩估计方法 (Adam) 执行梯度下降。Adam 是一种广泛用于深度学习的优化算法，通过计算梯度的一阶矩和二阶矩（均值和方差）自适应调整每个优化变量的学习率，在不依赖全局梯度信息的前提下，提升收敛稳定性和收敛速度^[66]。

设待优化面型参数为 θ ，其在每轮迭代过程中通过自动微分技术获得的目标函数关于待优化参数的梯度信息为 $\nabla_{\theta} Loss$ ，具体参数更新步骤如下。

(1) 初始化一阶矩向量 $\mathbf{m}$ 和二阶矩向量 $\mathbf{v}$ ，初始值均为零。

(2) 对于第 k 次迭代，根据式(3-15)(3-16)计算更新 $\mathbf{m}^{(k+1)}$ ， $\mathbf{v}^{(k+1)}$ 。

$$\mathbf{m}^{(k+1)} = \beta_1 \mathbf{m}^{(k)} + (1 - \beta_1) \nabla_{\theta} Loss^{(k)} \quad (3-15)$$

$$\mathbf{v}^{(k+1)} = \beta_2 \mathbf{v}^{(k)} + (1 - \beta_2) (\nabla_{\theta} Loss^{(k)})^2 \quad (3-16)$$

其中 β_1 和 β_2 分别为一阶矩估计和二阶矩估计的衰减率，分别设置为 0.9 和 0.999。通过式(3-17)和(3-18)将 $\mathbf{m}^{(k+1)}$ 和 $\mathbf{v}^{(k+1)}$ 矫正为 $\hat{\mathbf{m}}^{(k+1)}$ 和 $\hat{\mathbf{v}}^{(k+1)}$ ，消除偏差带来的影响。

$$\hat{\mathbf{m}}^{(k+1)} = \frac{\mathbf{m}^{(k+1)}}{1 - \beta_1^k} \quad (3-17)$$

$$\hat{\mathbf{v}}^{(k+1)} = \frac{\mathbf{v}^{(k+1)}}{1 - \beta_2^k} \quad (3-18)$$

(3) 通过式(3-19)更新待优化参数：

$$\theta^{(k+1)} = \theta^{(k)} - \eta \frac{\hat{\mathbf{m}}^{(k+1)}}{\sqrt{\hat{\mathbf{v}}^{(k+1)} + \epsilon}} \quad (3-19)$$

其中 η 为决定每次迭代步长的学习率， ϵ 为一个很小的常数，避免分母出现零，提高数值稳定性。

更新后的定日镜面型参数再通过前向仿真计算集热器上的辐射能密度分布情况。

3.4 实验结果与讨论

本章提出的基于可微光线追踪的定日镜面型优化方法采用 Taichi 框架开发实现，代码采用 Python 3.9 编写。本文实验在一台配备了 Intel(R) Core i5-10400F (2.90 GHz) 处理器和 NVIDIA RTX 3090 GPU 的台式计算机上完成。本节首先采用定日镜反射光斑的实测数据验证前向聚光仿真算法的准确度，再通过单时刻焦距优化实验验证了本文优化方法的可行性，为后续具体定日镜面型优化任务奠定技术基础。

3.4.1 前向仿真验证实验

为了验证前向仿真算法的仿真精度，本节将定日镜聚光仿真算法的仿真结果与真实镜场实测数据进行对比验证。实验图像和数据来源于中国西北部一实际镜场的定日镜检测系统，选取了两组具有代表性的定日镜反射光斑图像作为验证样例。这些光斑图像由工业相机采集，拍摄对象为集热塔上放置的定日镜标定白板。实验涉及的集热器参数、定日镜参数和环境参数等具体参数值如表 3.1 所示。

表 3.1 前向仿真验证实验场景参数

对象	参数	数值	
		测试 1	测试 2
集热器	类型	平板型	
	朝向	西向	东向
	宽(m)	17	
	高(m)	17	
	全局坐标(m)	(0.0, 165.0, 0.0)	
	像素尺寸(m ²)	0.1 × 0.1	
定日镜	尺寸(m ²)	5.6 × 3.7	
	全局坐标(m)	(-775.8, 3.0, 5.9)	(800.3, 3.0, 17.7)
	法向扰动 σ_s (mrad)	1	
	玻璃层厚度(mm)	3	
	玻璃层折射率	1.5	
	日期和时间	4 月 26 日 8:43	4 月 18 日 13:48
太阳	太阳形状模型	Buie	
	CSR	0.1	

为了确保仿真结果与实测结果具有可比性，需要对原始图像需要经过一系列预处理，包括剪裁、几何校正、背景色去除以及颜色归一化等。仿真光斑与实测光斑的对比结果如图 3.7 所示。其中，第一列为原始拍摄图像，第二列为预处理后的图像，第三列为前向聚光仿真算法仿真得到的光斑与实测数据的对比结果，图中数字为归一化辐射能密度相对值。可以看出，通过本文方法仿真得到的光斑在形状、尺寸以及能量分布情况与实测数据高度吻合，验证了本文采用的全通路反向蒙特卡洛光线追踪算法的准确性，为后续的优化工作提供了可靠的物理模型基础。




图 3.7 仿真光斑与实测光斑对比图

3.4.2 优化方法验证实验

为了验证基于可微光线追踪的定日镜面型优化方法能够有效实现面型优化任务，本小节设计了一个单时刻下的定日镜焦距优化实验，场景参数与 3.4.1 中测试 1 的场景参数保持一致，不同的是采用旋转抛物面来表示定日镜表面形状，如式(3-20)所示，优化变量为焦距 f ，以 $1500m$ 作为优化初值，模拟初始状态是平面型定日镜。目标函数为该测试时刻下的定日镜反射光斑的 S_{95} 。

$$z = \frac{x^2 + y^2}{4f} \quad (3-20)$$

对于测试 1 中的定日镜来说，其距离集热器表面的距离是 $792m$ ，即从几何聚光关系出发，该位置上的旋转抛物面的理想焦距应该是 $792m$ 左右。具体优化的迭代过程如图 3.8 所示。




图 3.8 优化迭代过程

可以看到，采用本章提出的基于可微光线追踪的定日镜面型优化方法，优化变量焦距 f 沿着梯度方向快速下降，在第 9 代左右收敛到了最优值，最优焦距为 $781m$ ，与预期较为接近。由于测试时刻为 4 月 26 日 8:43，此时定日镜、集热器和太阳并未严格共线，最优焦距与几何距离的 $792m$ 之间存在一定偏差是合理的。从图 3.8(c) 中能够看到目标函数 S_{95} 关于焦距 f 的梯度在优化过程中逐渐收敛到 0 附近，这也表明本文在采用 *sigmoid* 函数处理光斑辐射能分布图像后计算的 S_{95} 是可微的，能够通过自动微分技术获得相对优化变量的梯度信息，从而实现面型优化任务。

本文同时采用粒子群算法 (Particle Swarm Optimization, PSO) 对焦距 f 进行优化，两种算法的优化情况如表 3.2 所示。可以看到两种方法获得的最优解基本一致，但由于粒子群算法需要通过若干粒子进行大量重复的仿真计算，而可微光线追踪方法利用梯度信息实现确定性更新，可以将需要的仿真次数从 480 次降至 9 次，因此本文提出的可微优化方法在计算效率上具有显著的优势。

表 3.2 焦距优化实验的优化方法对比

优化方法	最优焦距 $f(m)$	迭代次数	仿真次数	优化时间(s)
可微光追	781.4	9	9	0.65
粒子群	781.7	24	480	11.68

3.5 小结

本章围绕提升塔式太阳能热发电系统定日镜面型优化效率的核心目标，针对传统方法依赖大量重复仿真、计算成本高的瓶颈，提出了一种基于可微光线追踪的定日镜面型优化方法。该方法通过将高精度的光线追踪过程与梯度优化算法相融合，为实现高效、精确的定日镜面型优化奠定了理论基础。

本章系统阐述了优化流程的整体框架，包括前向光斑仿真与后向面型优化两个核心环节。在前向仿真环节，采用全通路反向蒙特卡洛光线追踪算法，综合考虑太阳形状、镜面法向扰动、大气衰减等光学因素，实现对反射光斑辐射能密度分布的高精度仿真；在优化目标方面，引入光斑 95% 能量覆盖面积 S_{95} 作为评价聚光性能的核心指标，并针对其不可微性，创新性地采用 *sigmoid* 函数对其不可微性进行平滑处理，使其具备可微性，从而支持梯度反向传播。

在后向优化中，基于 Taichi 框架的自动微分机制，构建了光线追踪过程的可微计算图，实现了目标函数对定日镜面型参数的高效梯度求解。在此基础上，采用自适应矩估计优化算法对梯度信息进行自适应学习率更新，实现对定日镜面型参数的快速迭代求解。

为验证方法的可靠性，本章设计了系统的验证实验。前向仿真结果表明，仿真光斑与实测数据高度吻合，证明了光线追踪算法的准确性；单镜焦距优化实验则验证了可微优化方法的可行性与高效性。

综上所述，本章提出的方法创新性地实现了蒙特卡洛光线追踪过程的可微化，使仿真全程可计算梯度，从而将梯度优化直接嵌入仿真流程。这不仅避免了启发式算法的高计算开销，也为后续定日镜面型优化及镜场应用提供了高效的优化工具。